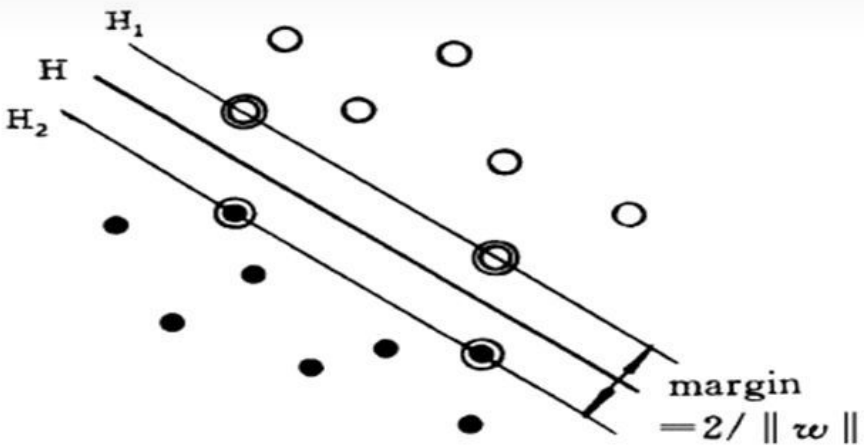

拉格朗日对偶性

Eureka

369 人赞同了该文章

专栏文章汇总

文章结构如下：

1： 原始问题

2： 对偶问题

3： 原始问题和对偶问题的关系

4： 参考文献

在约束最优化问题中，常常利用拉格朗日对偶性(Lagrange duality)将原始问题转为对偶问题，通过解决对偶问题而得到原始问题的解。

对偶问题有非常良好的性质，以下列举几个：

1. 对偶问题的对偶是原问题；
2. 无论原始问题是否是凸的，对偶问题都是凸优化问题；
3. 对偶问题可以给出原始问题一个下界；
4. 当满足一定条件时，原始问题与对偶问题的解是完全等价的；

1： 原始问题

假设 $f(x), c_i(x), h_j(x)$ 是定义在 R^n 上的连续可微函数。
称约束最优化问题

▲ 赞同 369 ▼ 16 条评论 分享 喜欢 收藏 申请转载 ···

$$
\begin{aligned}
s.t. \quad & c_i(x) \le 0, \quad i = 1, 2, \cdots, k \\
& h_j(x) = 0, \quad j = 1, 2, \cdots, l
\end{aligned}
$$

为原始最优化问题或原始问题。

首先引入拉格朗日函数（generalized Lagrange function）

$$
L(x, \alpha, \beta) = f(x) + \sum_{i=1}^{k} \alpha_i c_i(x) + \sum_{j=1}^{l} \beta_j h_j(x)
$$

其中， $x = \left(x^{(1)}, x^{(2)}, \cdots, x^{(n)}\right)^T \in R^n, \alpha_i, \beta_j$ 是拉格朗日乘子， $\alpha_i \ge 0$ 。

构建关于 x 的函数

$$
\theta_P(x) = \max_{\alpha, \beta; \alpha_i \ge 0} L(x, \alpha, \beta)
$$

假设给定某个违反原始问题约束条件的 x ，即存在某个 i 使得 $c_i(x) > 0$ 或 $h_j(x) \ne 0$ 。若 $c_i(x) > 0$ ，可令 $\alpha_i \to +\infty$ ，使得 $\theta_P(x) = +\infty$ ；若 $h_j(x) \ne 0$ ，可令 β_j 使 $\beta_j h_j(x) \to +\infty$ ，使得 $\theta_P(x) = +\infty$ 。将其余 α_i, β_j 均取值为0。
即

$$
\theta_P(x) = \max_{\alpha, \beta; \alpha_i \ge 0} \left[f(x) + \sum_{i=1}^{k} \alpha_i c_i(x) + \sum_{j=1}^{l} \beta_j h_j(x) \right] = +\infty
$$

假设给定某个符合原始问题约束条件的 x ，即 $c_i(x) \le 0$ 且 $h_j(x) = 0$ ，
则

$$
\theta_P(x) = \max_{\alpha, \beta; \alpha_i \ge 0} \left[f(x) + \sum_{i=1}^{k} \alpha_i c_i(x) + \sum_{j=1}^{l} \beta_j h_j(x) \right] = f(x)
$$

由以上，得

$$
\theta_P(x) = \begin{cases} f(x), x\text{满足原始问题约束} \\ +\infty, \text{否则} \end{cases}
$$

则极小化问题

$$
\min_x \theta_P(x) = \min_x \max_{\alpha, \beta; \alpha_i \ge 0} L(x, \alpha, \beta)
$$

与原始最优化问题等价，即有相同的解。（因为当趋向无穷时，问题无解，因此必须满足约束条件）

$$
\min_x \max_{\alpha, \beta; \alpha_i \ge 0} L(x, \alpha, \beta)
$$

$$p^* = \min_x \theta_P(x)$$

称为原始问题的值。

2： 对偶问题

构建关于 α, β 的函数

$$\theta_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)$$

则极大化问题

$$\max_{\alpha,\beta;\alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha,\beta;\alpha_i \geq 0} \min_x L(x, \alpha, \beta)$$

称为广义拉格朗日函数的极大极小问题。

将广义拉格朗日函数的极大极小问题表示为约束最优化问题

$$\begin{aligned} &\max_{\alpha,\beta;\alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha,\beta;\alpha_i \geq 0} \min_x L(x, \alpha, \beta) \\ &s.t. \quad \alpha_i \geq 0, \quad i = 1, 2, \cdots, k \end{aligned}$$

称为原始问题的对偶问题。

定义对偶问题的最优值

$$d^* = \max_{\alpha,\beta;\alpha_i \geq 0} \theta_D(\alpha, \beta)$$

称为对偶问题的值。

3： 原始问题和对偶问题的关系

若原始问题与对偶问题都有最优解，则

$$d^* = \max_{\alpha,\beta;\alpha_i \geq 0} \min_x L(x, \alpha, \beta) \leq \min_x \max_{\alpha,\beta;\alpha_i \geq 0} L(x, \alpha, \beta) = p^*$$

这个性质便叫做弱对偶性（weak duality），对于所有优化问题都成立，即使原始问题非凸。

强对偶是一个非常好的性质，因为在强对偶成立的情况下，可以通过求解对偶问题来得到原始问题的解，在 SVM 中就是这样做的。当然并不是所有的对偶问题都满足强对偶性，在 SVM 中是直接假定了强对偶性的成立，其实只要满足一些条件，强对偶性是成立的，比如说 Slater 条件与KKT条件。

Slater条件：对于原始问题及其对偶问题，假设函数 $f(x)$ 和 $c_i(x)$ 是凸函数，$h_j(x)$ 是仿射函数，且不等式约束 $c_i(x)$ 是严格可行的，即存在 x，对所有 i 有 $c_i(x)<0$，则存在 x^*,α^*,β^*，使 x^* 是原始问题的解，α^*,β^* 是对偶问题的解，并且

$$p^*=d^*=L(x^*,\alpha^*,\beta^*)$$

也就是说如果原始问题是凸优化问题并且满足 Slater 条件的话，那么强对偶性成立。需要注意的是，这里只是指出了强对偶成立的一种情况，并不是唯一的情况。

KKT条件：对于原始问题及其对偶问题，假设函数 $f(x)$ 和 $c_i(x)$ 是凸函数，$h_j(x)$ 是仿射函数，且不等式约束 $c_i(x)$ 是严格可行的，即存在 x，对所有 i 有 $c_i(x)<0$，则存在 x^*,α^*,β^*，使 x^* 是原始问题的解，α^*,β^* 是对偶问题的解的充分必要条件是 x^*,α^*,β^* 满足下面的Karush-Kuhn-Tucker(KKT)条件：

$$\begin{aligned}
&\nabla_x L(x^*,\alpha^*,\beta^*)=0\\
&\alpha_i^* c_i(x^*)=0,\quad i=1,2,\cdots,k\\
&c_i(x^*)\le 0,\quad i=1,2,\cdots,k\\
&\alpha_i^*\ge 0,\quad i=1,2,\cdots,k\\
&h_j(x^*)=0,\quad j=1,2,\cdots,l
\end{aligned}$$

总的来说就是说任何满足强对偶性的优化问题，只要其目标函数与约束函数可微，任一对原始问题与对偶问题的解都是满足 KKT 条件的。即满足强对偶性的优化问题中，若 x^* 为原始问题的最优解，α^*,β^* 为对偶问题的最优解，则可得 x^*,α^*,β^* 满足 KKT 条件。

KKT详见：Karush-Kuhn-Tucker (KKT)条件

小结：本文介绍了对偶的基本概念，对于一个约束优化问题，找到其对偶问题，当弱对偶成立时，可以得到原始问题的一个下界。而如果强对偶成立，则可以直接求解对偶问题来解决原始问题。SVM 就是这样的。对偶问题由于性质良好一般比原始问题更容易求解，在 SVM 中通过引入对偶问题可以将问题表示成数据的内积形式从而使得 kernel trick 的应用更加自然）。

4： 参考文献

李航. 统计学习方法[M]. 北京：清华大学出版社，2012

支持向量机：Duality " Free Mind

发布于 2018-06-17 02:40

统计学习方法 SVM 拉格朗日（J.-L. Lagrange）

namasikanam
看到这个参考文献.....我竟然真的是在知乎复习.....
2019-06-28 7

Recursion
如果原问题不是凸优化问题，对偶的对偶并不一定是原问题。。。
2019-06-28 7

轮子
第一条性质和第二条性质是不是有条件？否则可以因为任何问题的对偶问题都是凸的，对偶问题的对偶又是原问题，可以推出任何问题都是凸的
2021-04-22 1

艾伦·布拉德
如何证明svm是满足强对偶性的呢？
2020-09-09 1

edgadwewf
因为是convex
2021-04-19 赞

咕噜咕噜
请问是先由slater条件说明强对偶性，再由kkt条件解出最优解吗？
2021-11-07 赞

lucky
你好，请教下，为什么无论原始问题是否为凸函数，对偶问题一定是凸优化问题？
2019-11-04 赞

xssyyyyy
因为对偶函数是一族关于(alpha, beta)的仿射函数的逐点下确界，对偶函数是凹函数
2020-04-11 赞

穆阿卖提贺六浑
请问，弱对偶性怎么证出来的呢，是形式上就这样的吗？求依据~
2019-10-18 赞

与苏
直接套用Max–min inequality可证
2020-04-06 赞

威尼斯的大海
好文。
2019-10-14 赞

江东鲁大师
吼吼吼

2019-02-10 赞

SchoolDays
谢谢~
2018-06-17 赞

Eureka 作者
客气，我自己也是学习ing
2018-06-17 1

王小二的拖拉机
抄书这么多赞…
05-29 赞

写下你的评论...

文章被以下专栏收录

Eureka机器学习读书笔记
金融民工的机器学习之路

推荐阅读

拉格朗日对偶性

在约束最优化问题中，常常利用拉格朗日对偶性（Lagrange duality）将原始问题转换为对偶问题，通过解对偶问题而得到原始问题的解。该方法应用在许多统计学习方法中，例如，最大熵模型与支持...

Pikachu5808

拉格朗日对偶

摘要：优化问题原问题求解起来往往非常复杂，这个时候需要构建对偶问题来进行求解，如果原问题是凸模型，那么对偶问题的最优解就是原问题的最优解。这篇文章主要介绍拉格朗日对偶方法的来龙...

谭本东 发表于数学优化

拉格朗日对偶问题

1.原始问题假设 f(x), C_{i}(x), h_{j}(x)是定义在R^{n}上的连续可微函数，考虑约束最优化问题： \min _{x \in R^{n}} f(x) \\\left\{\begin{array}{c}\text {s.t. } C_{i}(x) \leq 0, i=1,...

路小灰

拉格朗日对偶
C)

利用 拉格朗日
最优化的原始
小极大问题)，
的对偶问题(拉
题)。 原始问题
C}\max_{\ome

Arlen